

论文综述

小组成员：何砾杰、胡书睿、王云平、朱均怡、侯葳

摘要

abstract

汽车行业是关乎国家经济命脉，体现国家工业实力的重要行业，汽车行业和其他高科技行业的联系会越来越深。而且随着技术的成熟，市场的渗透率持续加深，未来的发展空间越发壮大。

可以说自动驾驶代表了汽车行业的发展方向，这是毋庸置疑的事情。但自动驾驶依旧有许多目前尚未解决的难题。例如多车协同，路径规划，全路段自动驾驶等。这些问题伴随着人工智能的技术发展与硬件的提升将会被逐步化解。

本论文针对深度学习与强化学习这两个机器学习的两大热点话题对于自动驾驶问题提出未来解决思路。我们分析了近 100 篇论文，对于重点的有价值论文着重分析，对其发表日期，提出的解决思路，与未来的前景做出讨论。


最终本篇总述实现了目前论文解读的可视化，并对于重要的论文着重分析，得出自动驾驶历史发展的关键节点和未来前景。

论文数据可视化

我们小组共阅读约 90 篇自动驾驶相关论文，取其中与人工智能相关的 76 篇。改论文与深度学习或强化学习均有关联。在论文中探讨了一个或者多个的模型，对于自动驾驶的相应场景有一定解决思路。

1. 论文分布


在 76 篇论文中，我们依据引用量，对于引用量低于 20 的论文排除出我们的探讨内容，因为这些论文在它的研究领域可能并没有太大价值。我们筛选出 42 篇论文。其中 6 篇是文献综述也就是整理已有算法，并没有在论文中有相应研究，剩余的 36 篇作出实际研究的论文中也有 10 篇没能得出相应的结论，他们可能提出了算法方向但没有数据支撑，也可能模型并没有得出符合预期的结果。




在图中可见，文献综述在其中仅占非常小的份额，但其中不乏具有相当影响力的论文。例如

他们发表于 2019 年 10 月在计算科学 (ComputerScience) 的论文，改论文就介绍基于 AI 的自动驾驶架构，卷积和递归神经网络，以及深度强化学习范式。这些方法构成了被调查的驾驶场景感知，路径规划，行为仲裁和运动控制算法的基础。此外还解决了当前在设计自动驾驶 AI 架构时遇到的挑战，例如其安全性，训练数据源和计算硬件。在该调查中提供的比较有助于深入了解深度学习和人工智能方法在自动驾驶方面的优势和局限性，并有助于设计选择。

这 42 篇论文均是 2015 年之后发表的。可见自动驾驶话题再近几年的火热，但由于之前智能算法的局限，也因此发展受到限制。未来随着更多机器学习（包括深度学习、强化学习、深度强化学习等算法）的深入研究，未来会涌现出更多的智能驾驶解决方案。



接下来我们分析了论文所运用的算法的分布。在这 42 篇论文中仅包含强化学习的有 5 篇。包含深度学习的论文有 27 篇。其余 10 篇既包括强化学习也涉及深度学习，又少不凡深入探讨了深度强化学习的可能性。



深度学习因为它的广泛的应用性，被更多人所采用。深度学习的算法，包括 CNN，RNN，LSTM，ANN，Le-net 等模型，可以被应用在路线规划，意向预测，轨迹预测，车辆控制等多个场景。所受到的限制较少，因此被更多人选择。然而其面对突发状况的解决能力的欠缺，也是当前模型训练的难点。解决办法往往只有增大算力与增加数据量等，也因此带来了模型庞大，运算超时等后果。

强化学习因其时序特性，在解决一段时间内的车辆规划问题，尤其是多车协同问题有先天的优势。因此在智能驾驶的发展过程中始终有着一席之地。

深度强化学习，随着 Alphago 的出现，让更多人知道了它的强大算力。它结合了深度学习的多层感知能力也融入了强化学习的时序优化能力。在处理有延时反馈且复杂的问题时，凸显了它的重要性。

2. 自动驾驶的方向探讨

未来自动驾驶的多个领域总结为大致 5 个方向：

① 感知

感知所代表的是包括雷达，图像，测距仪等多个仪器的综合感知能力。包括目前天气的感知能力，所在道路车况的感知能力，汽车行驶状况的感知能力等，是自动驾驶汽车的眼睛。汽车的综合感知能力将车的行驶状况转化为数据，作为依据交给后面的决策来判断。

② 定位

定位主要是汽车行驶的位置判断，例如所行驶的位置，错误路径的矫正等。

③ 规划

规划即路径规划。根据前面的感知与定位，做出合理的行车轨迹的规划。例如为了避免前方车流选择更节省时间的路径，或者为了节省油耗选择更加适中的形式速度。

④ 控制


控制即掌控汽车的行驶并不偏离规划的路径。在不同的时速下，转弯的半径会由于摩擦力等因素，并不是按照理想的角度实现的。自动驾驶的控制，未来就是实现满足不同情况下行驶在规划路径上。

⑤ 多车协同

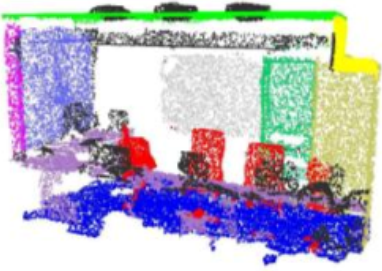
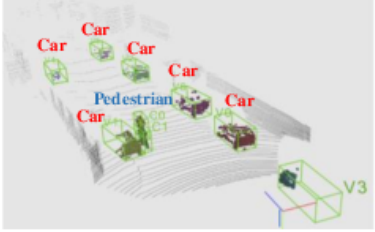
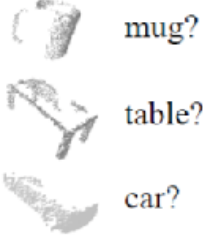
多车协同是局部交通的有效解决办法。例如十字路口的多辆车的交汇，理想的多车协同模型可以实现高峰时期的错峰汇流。又例如某封闭场景内的多辆无人驾驶小车的多车协同。

3. 所用算法的探讨

深度学习方向采用 CNN、RNN 即卷积神经网络与传统神经网络的居多。他们多实现高速公路车道检测(An Empirical Evaluation of Deep Learning on Highway Driving,2015.4.7)，自动驾驶控制系统（DeepDriving: Learning Affordance for Direct Perception in Autonomous Driving, 2015.5.1）等方向，在较早被提出。



而在之后的论文中,更多融入了新的思路与技术改进原有的自动驾驶。在 Deep Learning for LiDAR Point Clouds in Autonomous Driving: A Review (2020) 论文中,加入了点云模型在车辆感知的模块,该论文在点云模型中实现了语义分割、目标检测和定位、分类和识别等任务。

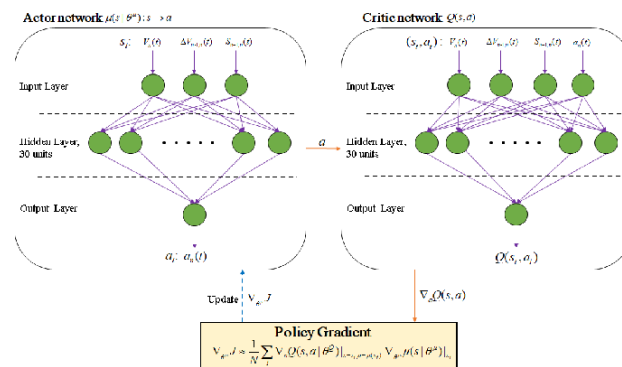
 <p>(a) Point Cloud Segmentation</p>	<ul style="list-style-type: none"> • Diversified point density and reflective intensity (Depending on the distance between objects and LiDAR sensors) • Noisy (Originated from sensors, such as point perturbations and outliers) • Incompleteness (Caused by occlusion between objects and cluttered background) • Confusion categories (Caused by shape-similar or reflectance similar objects) <p>(d) Challenges on data</p>
 <p>(b) 3D object detection</p>	<ul style="list-style-type: none"> ➤ Permutation and orientation invariance (Caused by unordered and unoriented data structure) ➤ Rigid transformation challenge (e.g., 3D rotations and translations) ➤ Big data challenge (LiDAR collects millions to billions of points in different scenes) ➤ Accuracy challenge (Caused by vast range of intra- and extra-class variations and the quality of data) ➤ Efficiency challenge (Caused by limited computational capabilities and storage space) <p>(e) Problems for DL models</p>
 <p>(c) 3D object classification</p>	

也有部分论文改进了原有的算法框架例如 CNN 等。A deep learning algorithm for simulating autonomous driving considering prior knowledge and temporal information 论文中采用了 CNN-LSTM 的联合模型，LSTM 是长短期记忆神经网络，它结合了卷积神经网络的局部感知与参数共享的优势，也解决了长期重复问题，改论文主要解决了驾驶决策的问题。

总结强化学习和深度学习的特点


① Reinforcement learning 强化学习

强化学习是机器学习的一大组成部分，它区别与传统机器学习的特点在于交互与延时奖励。它会根据观察目前的形势（observation）作出决策（action），决策会导致相应的结果（reward）并且出现新的形势。由于随机的特性，因此这也是一个马尔可夫过程，强化学习就是在这时序过程中取得最优解。



游戏领域是强化学习应用最多也是表现最直观的领域，有些游戏的 ai 会使用强化学习实现 npc 的决策。以 alphago 为例，alphago 通过观察场上的棋形，作出落子的决策和落子带来的反馈，不断改进自己的策略。（alphago 实际为深度强化学习，包括多层神经元参与的决策网络,所以严格上说 alphago 不仅是强化学习）

说回自动驾驶方面，由于强化学习的时序性，它主要运用于决策领域，例如多车协同，路口调度等情况。这是因为这些情形有反馈的特性，前一辆车的变道势必会影响后面汽车的决策，如何稳定好一段时间内的车流便体现了强化学习的优势。



②Deep learning 深度学习

深度学习也是机器学习的一个分支，是一种以人工神经网络为架构，对数据进行特征学习的算法。目前发展势头较猛，主要应用在人脸技术、图象识别、智能监控、文字识别、语义分析等领域。

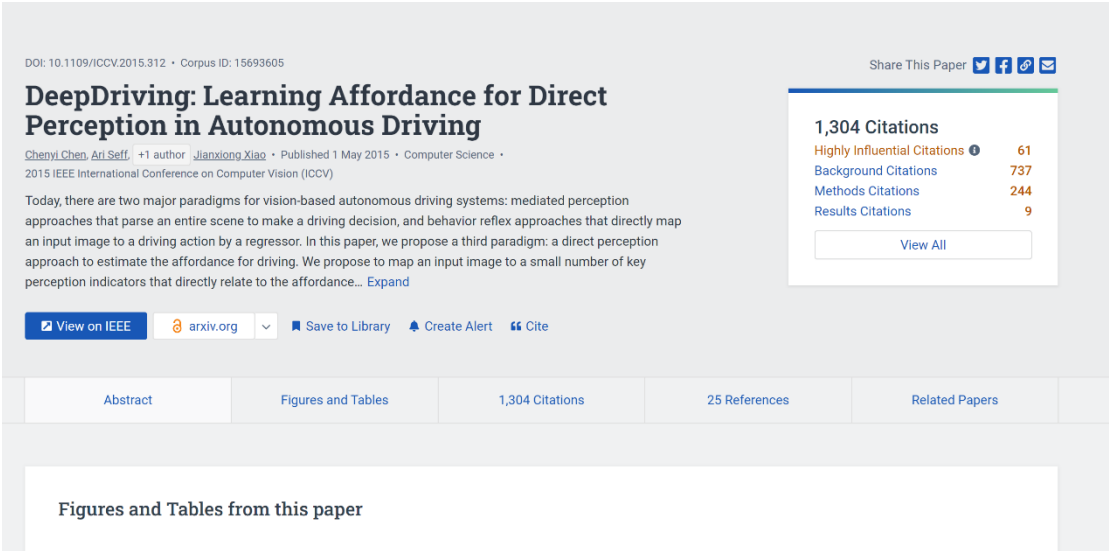


Figure 2: Illustration of multi-agent simulation in Unity

相比于强化学习的局限性, 深度学习在自动驾驶方面使用的场景就较为丰富, 包括感知, 定位, 规划, 控制等。例如感知, 就是确定图像探测到的是车, 是人, 还是路灯? 而定位则包括确定车在哪条车道? 甚至要精确到车道偏左还是偏右几厘米。

有价值论文举例浅析

DeepDriving: Learning Affordance for Direct Perception in Autonomous Driving



这篇文章是关于神经网络在自动驾驶的应用改进, 它的第一作者中国人 Chenyi Chen, 这篇论文有 1301 的引用量, 尽管是 2015 年作出的论文, 但他依旧有很高价值。这篇论文指出, 基于视觉的传统自动驾驶有两大范畴: 1. 中介感知法, 即根据图像与雷达等模拟出一个场景再在场景中作出决策; 2. 行为反射法, 也就是训练一个根据输入图像可以输出相应决策的回归 (regressor)。在这篇论文中却提出了第三种思路, 直接感知法。简单来说就是从图像中提取出主要特征, 例如前方车辆距离, 目前车道位置, 左右两车道的汽车情况等。根据这些主要特征, 模拟出一个简要的场景, 最终训练了一个深度卷积神经网络作出决策。论文利用了 12 小时的驾驶视频来检测, 做到可以有效的应用在真实场景中。

